

Problem Set 3

Big Data & Machine Learning

Profesor: Ignacio Sarmiento

Grupo 9

Santiago Melo - 202324572

Miguel Blanco - 202412541

Diana Lopera - 1130639521

Link repositorio: https://github.com/samelomo99/PS3_SM_MB_DL

1. Introducción

La predicción precisa del precio de la vivienda constituye un desafío fundamental en el análisis del mercado inmobiliario, debido a su impacto directo en la calidad de vida de los hogares y en la toma de decisiones de actores públicos y privados. Desde entidades de planificación urbana hasta inversionistas y compradores individuales, una adecuada estimación del valor de los inmuebles es clave para orientar decisiones eficientes y sostenibles.

Sin embargo, la valoración de propiedades enfrenta la complejidad de mercados altamente heterogéneos, en los que los precios no solo dependen de características físicas de la vivienda, sino también de factores espaciales, sociales y temporales. La variabilidad observada entre inmuebles, incluso dentro de una misma ciudad, ha impulsado el uso de modelos estadísticos y de *machine learning* que permiten capturar esta heterogeneidad con mayor precisión.

En este contexto, el presente estudio tiene como objetivo construir un modelo predictivo del precio de oferta de viviendas residenciales a partir de sus características observables, considerando que la relación funcional entre atributos y precios no está teóricamente definida. Para ello, se comparan distintos modelos de **machine learning** con el fin de identificar cuál ofrece el mejor desempeño predictivo en la localidad de Chapinero (Bogotá).

El análisis se basa en un conjunto de datos extraído del portal Properati, enriquecido con información proveniente de fuentes externas y técnicas de procesamiento de lenguaje natural (PLN). Además de variables estructurales como área total, área construida, número de habitaciones, baños y tipo de propiedad, se incorporaron variables binarias —como ascensor, depósito y parqueadero— extraídas automáticamente de descripciones en texto libre. También se añadieron variables geoespaciales, como la distancia al parque o a la avenida principal más cercana (calculadas mediante Open Street Maps), así como la cercanía a centros comerciales y estaciones de TransMilenio, con base en datos de la Secretaría Distrital de Planeación y del sistema de transporte público.

A nivel nacional, los estudios sobre predicción de precios de vivienda en Colombia aún son escasos. Buitrago (2021) desarrolló modelos para estimar el precio por metro cuadrado de vivienda nueva en Bogotá utilizando información del sistema Coordinada Urbana de Camacol. Su modelo incorporó tanto atributos del inmueble como del entorno urbano —por ejemplo, parqueaderos por vivienda, área construida, densidad poblacional, número de pisos y distancias a puntos de interés—, destacando la importancia de variables como el número de alcobas, la presencia de balcón o chimenea, y la localización geográfica, que resultó ser el principal determinante del precio. Entre las metodologías aplicadas, el árbol de regresión fue el que explicó con mayor

eficacia la varianza de los precios, alcanzando un 83,5 %.

En otro estudio, Soto y David (2021) evaluaron diversos algoritmos, entre ellos regresión **Ridge**, **Random Forest**, **Gradient Boosting**, **XGBoost** y **redes neuronales profundas**, para predecir precios de vivienda en el Valle de San Nicolás (Antioquia). Los modelos de árboles, especialmente **XGBoost**, lograron el menor error absoluto medio (MedAE), superando a las redes neuronales multicapa. Esta diferencia de desempeño se atribuye a la robustez de los modelos de **boosting** en el manejo de datos estructurados con múltiples variables categóricas y relaciones no lineales, así como a la necesidad de un mayor volumen de datos y una configuración más cuidadosa en el caso de las redes neuronales. Las variables más relevantes fueron el área construida, número de baños, ubicación geográfica, estrato, tipo de propiedad, antigüedad del inmueble y presencia de amenidades como balcones o cercanía a servicios.

Nieto (2023), por su parte, construyó un modelo predictivo para vivienda usada en Bogotá utilizando técnicas de **web scraping** y algoritmos de **boosting**. Aunque su enfoque no incluyó PLN ni redes neuronales, alcanzó un MAPE de 15,58 %, lo que reafirma la eficiencia de los métodos basados en gradientes en contextos urbanos densamente segmentados.

A nivel internacional, Picardo (2019) aplicó métodos estadísticos y de aprendizaje automático al mercado inmobiliario de Montevideo. Su análisis comparativo entre regresión lineal, árboles de decisión y bosques aleatorios evidenció que estos últimos ofrecían un mejor desempeño, especialmente cuando se incluía información georreferenciada, como distancias a servicios urbanos.

En conjunto, la evidencia nacional e internacional indica que los modelos que incorporan información espacial y contextual mejoran de forma sustancial la capacidad explicativa del precio de la vivienda. Aunque las redes neuronales presentan un alto potencial teórico para este tipo de predicciones, los estudios recientes no han demostrado ventajas concluyentes frente a modelos más interpretables y eficientes, como **XGBoost**, especialmente en contextos con datos limitados o principalmente estructurados. Además, las redes neuronales suelen requerir grandes volúmenes de datos, así como una cuidadosa selección y ajuste de hiperparámetros para alcanzar un desempeño óptimo. En contraste, los algoritmos basados en árboles de decisión muestran una mayor robustez y eficiencia al modelar relaciones no lineales y manejar múltiples variables categóricas en este tipo de datos.

Lo encontrado en la literatura se alinea con los resultados obtenidos en el ejercicio de predicción de precios de vivienda en Chapinero, donde el modelo de red neuronal más simple —tanto en términos de datos como de tasa de aprendizaje— demostró una mayor capacidad de generalización, alcanzando un MAE de \$277.389.181. En contraste, versiones del modelo con mayor complejidad, ya sea por la inclusión de variables imputadas o por el ajuste de hiperparámetros más agresivos, no lograron mejorar el desempeño y, en algunos casos, lo empeoraron.

Esto sugiere que un modelo más complejo no garantiza mejores resultados. Por el contrario, una arquitectura equilibrada, sin variables ruidosas y con una tasa de aprendizaje prudente, puede superar alternativas más sofisticadas pero sobreajustadas. Este ejercicio evidencia que, en el caso de las redes neuronales, la simplicidad acompañada de un buen preprocesamiento puede ser más efectiva que añadir complejidad. Asimismo, los resultados destacan el buen desempeño del modelo **XGBoost**, que alcanzó un MAE de \$281.290.366, muy cercano al de la red neuronal, lo que confirma su potencial como método robusto y competitivo en este tipo de ejercicios de predicción de precio de vivienda.

2. Datos

2.1. Descripción de los datos

Los datos utilizados para las estimaciones fueron obtenidos de diversas fuentes, que se enumeran a continuación: Properati, Datos Abiertos de la Secretaría Distrital de Planeación, Datos Abiertos de TransMilenio y OpenStreetMap. En la tabla 1 se describe el contenido de cada una de las variables empleadas en la base de datos y consideradas en las estimaciones.

A continuación, se detalla el proceso de construcción de cada una de las variables utilizadas, tanto aquellas que estaban incompletas en la base original de Properati como las generadas a partir de otras fuentes. En el caso de las variables *rooms* y *bathrooms*, los valores faltantes fueron reemplazados por la moda correspondiente: tres (3) para *rooms* y dos (2) para *bathrooms*. Para las variables *surface_total* y *surface_covered*, los valores faltantes fueron imputados utilizando la mediana de los valores existentes.

Cabe destacar que todas las propiedades listadas están ubicadas en Bogotá, por lo que no fue necesario aplicar filtros geográficos adicionales. En cuanto al tipo de propiedad, al revisar la base de datos se identificó que únicamente existen Apartamentos y Casas, por lo que tampoco fue necesario excluir otros tipos. Las variables *month* y *year* corresponden al mes y año de publicación, y permiten realizar un análisis temporal relacionado con la valorización.

La variable *distancia_parque* se construyó a partir de datos de OpenStreetMap. Con base en la ubicación de cada parque se generaron centroides, y la distancia entre estos y cada predio fue utilizada para construir dicha variable. De manera análoga, se creó la variable *distancia_avenida*, utilizando los datos de OpenStreetMap para las vías categorizadas como “highway” de tipo “trunk” y “primary”, que corresponden a los dos sistemas viales más importantes de Bogotá¹**openstreetmap**.

La variable *distancia_CC* se construyó a partir de una base de datos de centros comerciales registrados en el Plan de Ordenamiento Territorial, provista por la Secretaría de Planeación Distrital**CC**. En este caso, se generaron centroides para cada centro comercial, y la variable representa la distancia entre el predio y el centro comercial más cercano. De forma similar, la variable *distancia_tm* representa la distancia entre el predio y la troncal de TransMilenio más cercana, utilizando una base de datos proveniente de Datos Abiertos de TransMilenio S.A **tm**.

Las variables *parquedero*, *deposito*, *barrio* y *surface_3* se generaron a partir de las descripciones textuales de cada inmueble. Para su construcción se aplicaron técnicas de procesamiento de texto que permitieron extraerlas de manera eficiente. Por su parte, la variable *estrato* se obtuvo cruzando la ubicación de los inmuebles con la base de datos de estratos de la Secretaría Distrital de Planeación **estratos** disponible en Datos Abiertos. En los casos donde esta variable no se encontraba disponible, se utilizaron los datos del *barrio* para buscar el estrato correspondiente en fuentes en línea.

Finalmente, la variable *surface_3* fue construida así: ahora el script llamado prueba 5 llama a dos archivos anteriores y crea una nueva variable llamada *surface_3*, la cual fue creada de la siguiente forma: primero, con la descripción se creó la variable *area_predio_m2* usando lo de análisis de texto. Segundo, se crea *surface_2*, en la cual se construye usando *surface_total*, *surface_covered* y *area_predio_m2*, usando la siguiente lógica. Si *surface_total* tiene dato se deja ese valor, si no, revisamos si *surface_covered* tiene dato, en caso que si, se deja ese valor, si ninguno de esto tiene dato pero *area_predio_m2* tiene dato se deja ese, y sin ninguna de las 3 variables tiene dato entonces es un NA. Tercero, *surface_2_moda* coloca la moda del area en el barrio. Cuarto, *surface_3* se crea así, si *surface_2* tiene dato se deja ese dato, sino se toma el dato de *surface_2_moda*. Por último, cuando *surface_3* presentaba valores faltantes, estos fueron reemplazados por el promedio, diferenciando entre Casas y Apartamentos.

¹En OpenStreetMap existe una categoría superior llamada “motorway”, pero no se evidenció su presencia en Bogotá. En caso de haber existido, habría sido incluida.

Variable	Descripción
property_id	Corresponde al identificador individual de la propiedad.
city	Ciudad donde se ubica la propiedad, para el caso Bogotá.
price	Precio en el cual se publica la propiedad.
month	Mes de publicación.
year	Año de publicación.
surface_total	Variable que corresponde al área total del inmueble.
surface_covered	Variable que corresponde al área privada del inmueble.
rooms	Número de cuartos.
bedrooms	Número de habitaciones para dormir.
bathrooms	Número de baños.
property_type	Tipo de propiedad: si es apartamento o casa.
operation_type	Tipo de operación, que para el caso es venta.
lat	Latitud de ubicación del inmueble.
lon	Longitud de ubicación del inmueble.
title	Título de la publicación.
description	Descripción de la publicación.
precio_por_mt2	Cálculo del precio por metro cuadrado, obtenido dividiendo el precio (price) por el área total (surface_total).
distancia_parque	Cálculo de la distancia (en metros) entre la propiedad y el parque más cercano, con base en datos de Datos Abiertos Bogotá.
distancia_CC	Cálculo de la distancia (en metros) entre la propiedad y el centro comercial más cercano, según datos de la Secretaría de Planeación Distrital.
distancia_tm	Distancia en metros entre la propiedad y la troncal de TransMilenio más cercana.
distancia_avenida	Distancia en metros entre la propiedad y la avenida más cercana, usando datos de OpenMaps.
parqueadero	Variable dummy que indica si el inmueble tiene parqueadero o no, extraída de la variable descripción.
deposito	Variable dummy que indica si el inmueble tiene depósito o no, extraída de la variable descripción.
ascensor	Variable dummy que indica si el inmueble cuenta con ascensor, extraída de la variable descripción.
estrato	Estrato socioeconómico del inmueble, calculado con base en datos de Properati y la Secretaría de Planeación Distrital.
barrio	Barrio donde se encuentra el inmueble, a partir de los datos de la Secretaría de Planeación Distrital y las coordenadas disponibles de los inmuebles.
surface_3	Área del inmueble obtenida con base en su descripción textual.

Cuadro 1: Descripción de variables utilizadas en el análisis de precio de propiedades en Chapinero

2.2. Estadísticas Descriptivas

En las siguientes subsecciones se analizan algunas estadísticas con respecto a las propiedades y sus distancias a puntos importantes.

2.2.1. Base de datos de entrenamiento

Con respecto al estrato socioeconómico, se observa que la mayoría de los inmuebles listados pertenecen a los estratos 3, 4, 5 y 6, siendo el estrato 4 el más frecuente. Esta distribución resulta coherente con el perfil de la localidad de Chapinero, que se caracteriza por una alta presencia de población de ingresos medios y altos. Además, es probable que los inmuebles ubicados en estratos más bajos no se publiquen con la misma frecuencia en plataformas digitales, optando en cambio por mecanismos de comercialización más tradicionales o informales.

En cuanto al tipo de propiedad, el 77% de los inmuebles listados son apartamentos, mientras que el 23% corresponde a casas. Esta diferencia se alinea con el patrón de desarrollo urbano de Bogotá, especialmente en zonas de alta valorización como Chapinero, donde el crecimiento vertical ha sido la solución predominante frente a la limitada disponibilidad de suelo y la alta demanda habitacional. Estas tendencias se evidencian claramente en la Gráfica 1.




Figura 1: Características de la propiedad - Resto de localidades

Por otra parte, en promedio los inmuebles listados cuentan con tres habitaciones y dos baños, lo cual es consistente con la estructura típica de hogares compuestos por parejas con dos hijos, donde se destinan habitaciones separadas para cada niño. No obstante, al observar la distribución, se evidencia que es más común encontrar propiedades con dos habitaciones que con cuatro, lo que sugiere una oferta orientada hacia hogares más pequeños o parejas jóvenes. En cuanto al número de baños, la mayoría de los inmuebles cuenta con tres, siendo menos frecuentes las propiedades con un solo baño. Esto indica que la muestra incluye muy pocos apartaestudios o unidades habitacionales de tipo compacto, y que predomina una oferta residencial de tamaño medio a grande.

Con respecto a las distancias, se observa que en promedio las propiedades se encuentran a 155 metros de un parque, a 960 metros de un centro comercial, a 733 metros de la troncal de TransMilenio más cercana y a 287 metros de la avenida principal más próxima. Sin embargo, estas cifras promedio no implican una distribución uniforme de las distancias. En particular, las distancias a parques y centros comerciales pre-




Figura 2: Distribución de las distancias - Resto de las localidades

sentan distribuciones cercanas a una forma simétrica, similar a una campana, lo que sugiere una dispersión equilibrada en torno al promedio. Por el contrario, las distancias a troncales de TransMilenio y avenidas principales tienden a mostrar distribuciones sesgadas hacia la derecha, con una concentración de predios ubicados a distancias cortas y una cola larga hacia la derecha. Esto indica que muchas propiedades están ubicadas cerca de estas infraestructuras viales, mientras que unas pocas se encuentran considerablemente más alejadas. Estas características se pueden apreciar en la Gráfica 2.

2.2.2. Base de datos de prueba, Chapinero

Chapinero es una de las localidades más tradicionales y exclusivas de Bogotá, caracterizada por su diversidad urbana y socioeconómica. Se extiende desde la Diagonal 40 hasta la Calle 100, y desde los cerros orientales hasta la Avenida Caracas. Esta localidad alberga una mezcla de zonas residenciales, comerciales y de servicios, con una población residente de aproximadamente 125.750 personas y una población flotante que supera los 500.000 individuos diariamente, debido a la presencia de universidades, oficinas, centros comerciales y establecimientos de entretenimiento (Ciencuadras, 2022).

En esta localidad predominan los apartamentos, especialmente en sectores como Chapinero Alto y El Nogal; donde la construcción vertical funciona como respuesta a la alta demanda y limitada disponibilidad del suelo. No obstante, aún se conservan casas de gran tamaño, especialmente en barrios tradicionales como Rosales y La Cabrera. De hecho, Chapinero es la localidad con las casas más grandes de Bogotá, con un promedio de 149 m², superando en un 53 % el tamaño promedio de las casas en la ciudad (Bluradio, s.f.).

En cuanto a las características socioeconómicas, se puede observar una predominancia de estratos 4, 5 y 6, equivalentes al 92.51 % de las propiedades en Chapinero dentro de la base de datos. Barrios como El Chicó, El Retiro y La Cabrera son representativos del estrato 6, ofreciendo una amplia gama de servicios y equipamientos urbanos de calidad.




Figura 3: Características de la propiedades - Chapinero

Con respecto a las distancias, se observa que en promedio las propiedades en Chapinero están ubicadas a 160 metros de un parque, a 1.014 metros de un centro comercial, a 404 metros de la troncal de TransMilenio más cercana y a 208 metros de la avenida principal más próxima. Este patrón es coherente con la configuración urbana de la localidad, ya que Chapinero está atravesada por tres importantes avenidas: la Avenida Caracas, la Carrera Séptima y la Avenida Circunvalar. Cabe destacar que tanto la Caracas como la Carrera Séptima cuentan con troncales de TransMilenio, lo cual facilita el acceso al sistema de transporte público para una gran parte de los predios.

No obstante, estas cifras promedio no implican que las distribuciones de las distancias sean uniformes. La distancia a parques presenta una distribución aproximadamente simétrica, similar a una campana, lo que sugiere una cobertura relativamente homogénea de zonas verdes. En el caso de los centros comerciales, la distribución es bimodal, con dos picos, posiblemente reflejando la presencia de zonas con alta y baja accesibilidad comercial.

Por otro lado, las distancias a troncales de TransMilenio y avenidas muestran distribuciones asimétricas con una cola derecha pronunciada, lo que indica que la mayoría de los predios se encuentran cerca de estas infraestructuras, mientras que un número reducido está ubicado a distancias considerablemente mayores. Esta concentración de valores bajos sugiere una alta conectividad vial en la zona, aspecto que se evidencia en la gráfica 4.




Figura 4: Distribución de las distancias - Chapinero

3. Modelos y resultados

3.1. Selección y entrenamiento del modelo:

Esta sección presenta la descripción del modelo que obtuvo el mejor MAE en la competencia de Kaggle, alcanzando un valor de \$277.389.181,40 en el *leaderboard* privado y un MAE de \$279.322.882,56 en el público. La predicción enviada corresponde al archivo `pred_NN_keras_log.csv`, generado a partir de un modelo de red neuronal profunda implementado en R utilizando la librería `keras`.

La función estimada por el modelo se definió como:

$$\log(P_i) = f(\text{distancia_parque}_i, \text{distancia_CC}_i, \text{distancia_tm}_i, \text{distancia_avenida}_i, \text{rooms}_i, \text{bathrooms}_i, \text{property_type}_i, \text{ascensor}_i, \text{parqueadero}_i, \text{deposito}_i, \text{estrato}_i) + u_i \quad (1)$$

Donde:

- P_i representa el precio de la vivienda i .
- La variable dependiente fue transformada mediante logaritmo natural para estabilizar la varianza y mejorar el ajuste del modelo.
- Las variables categóricas se codificaron como *dummies* y las variables numéricas se estandarizaron.
- La función $f(\cdot)$ fue estimada mediante una red neuronal profunda, capaz de capturar relaciones no lineales complejas entre los predictores.

3.2. Estrategia de validación

La validación se realizó mediante una división tradicional *hold-out*, reservando el 20 % del conjunto original para evaluación fuera de muestra (80/20). Esta estrategia permitió verificar la estabilidad del modelo sin

añadir complejidad computacional. No se implementó validación cruzada espacial, lo cual representa una oportunidad de mejora para capturar la variabilidad geográfica en futuras versiones.

Otras decisiones metodológicas

- *Transformación de la variable dependiente*: Se aplicó logaritmo natural a **price**, lo que permitió estabilizar la variabilidad, reducir el sesgo de la distribución y mejorar el enfoque del modelo hacia errores relativos en lugar de extremos. Esta transformación mejoró notablemente el desempeño del modelo.
- *Preprocesamiento*: Todas las variables categóricas fueron codificadas con **one-hot encoding** y las numéricas estandarizadas usando **step_normalize()**. Estas transformaciones se integraron dentro de una **recipe** del ecosistema **tidymodels**, garantizando coherencia y reproducibilidad.
- *Número de épocas*: Se fijó en 400, suficientes para lograr la convergencia del modelo sin evidencia de sobreajuste. No se aplicó *early stopping*.
- *Tamaño de lote (batch size)*: Se utilizó el valor por defecto de **keras**, el cual resultó adecuado dado el tamaño del conjunto de datos.
- *Estructura del modelo*: Una capa de entrada, cuatro capas ocultas con 32 neuronas cada una y una capa de salida.
- *Funciones de activación*: ReLU en las capas ocultas y función lineal en la salida.
- *Función de pérdida*: Error cuadrático medio (MSE), acorde con la transformación logarítmica aplicada.
- *Optimizador*: Adam, con una tasa de aprendizaje de 0,01.
- *Entrenamiento*: No se aplicó *early stopping*, por lo que el modelo se entrenó durante todas las épocas especificadas.

3.3. Resultados del modelo

El ejercicio de evaluación fuera de muestra permitió tomar decisiones metodológicas clave para la estimación del modelo presentado en la competencia. Se estimaron modelos con los hiperparámetros definidos previamente, utilizando la variable **price** tanto en su forma original como transformada mediante logaritmo natural. Los resultados se presentan a continuación:

Cuadro 2: Comparación del MAE entre modelos con y sin transformación logarítmica

Modelo	MAE
Precio original	593.890.239
$\log(\text{price})$ revertido	139.699.303




Figura 5: Evolución de la función de pérdida durante el entrenamiento

Análisis comparativo de las especificaciones del modelo de red neuronal

Cuadro 3: Comparación de modelos de red neuronal profunda para predicción de precios de vivienda

Modelo	Capas (Unidades)	LR	Épocas	Imputación	Transformación	MAE Privado	MAE Público
Modelo 1 pred_NN_keras_log.csv	32-32-32-32	0.01	400	No	log(price)	277.389.181,40	279.322.882,56
Modelo 2 nn_keras_log_4layers500ep_lr0001	128-64-32-16	0.001	500	No	log(price)	292.915.811,16	296.535.594,94
Modelo 3 nn_keras_4layers600ep_lr001_knnimpute	64-64-32-16	0.01	600	KNN (surface_4)	log(price)	302.302.521,52	303.539.480,43

La evaluación de los tres modelos de red neuronal profunda permite identificar diferencias clave en su diseño y desempeño, reflejadas en los valores de MAE obtenidos tanto en el leaderboard privado como en el público de Kaggle.

El **Modelo 1** se destaca como el de mejor desempeño, con el MAE más bajo entre las tres propuestas. Su arquitectura es simple pero eficiente, compuesta por cuatro capas ocultas con 32 unidades cada una. Esta configuración, junto con una tasa de aprendizaje moderada (0,01) y el uso exclusivo de variables bien estructuradas sin imputación adicional, permitió alcanzar un equilibrio adecuado entre complejidad y capacidad de generalización. La ausencia de variables imputadas y la correcta transformación logarítmica del precio contribuyeron a una convergencia estable y efectiva.

El **Modelo 2** mostró un buen desempeño, aunque no logró superar al Modelo 1. Utilizó una arquitectura más robusta, con un mayor número de neuronas en las capas iniciales (128-64-32-16), y una tasa de aprendizaje más baja (0,001). Esta configuración favoreció una convergencia más estable pero también más lenta, lo que pudo haber limitado su capacidad para ajustarse óptimamente en el número de épocas definido (500). A pesar de su solidez, la falta de mejoras notables sugiere que una arquitectura más compleja no siempre garantiza un mejor resultado si no se acompaña de un ajuste adecuado del resto de los hiperparámetros.

El **Modelo 3**, por su parte, presentó el peor desempeño. Incorporó la variable `surface_4` con imputación mediante KNN, lo que probablemente introdujo ruido en los datos. A pesar de compartir la misma tasa de aprendizaje que el Modelo 1 (0,01), su entrenamiento por 600 épocas y la inclusión de variables imputadas podrían haber generado inestabilidad y sobreajuste. Esta combinación de factores llevó a un aumento significativo del MAE, evidenciando los riesgos de incorporar variables mal imputadas o de extender el entrenamiento sin control de calidad de los datos.

En conjunto, estos resultados refuerzan dos principios fundamentales del aprendizaje automático aplicado: (1) una arquitectura sencilla y bien balanceada, acompañada de un preprocesamiento cuidadoso, puede superar a modelos más complejos con ruido o hiperparametrización excesiva; y (2) el rendimiento de un modelo

no depende únicamente de su profundidad o del número de épocas, sino de un balance adecuado entre tasa de aprendizaje, diseño arquitectónico y calidad de las variables utilizadas. En este ejercicio, el Modelo 1 se posiciona como el más robusto en términos de generalización y efectividad predictiva. Por otro lado, el hecho de no haber realizado validación cruzada —principalmente por limitaciones de capacidad computacional— constituye un aspecto a mejorar, ya que permitiría una mejor combinación de hiperparámetros y una evaluación más sólida del desempeño fuera de muestra.

3.4. Comparación con demás modelos

Con respecto a los demás modelos, se observa lo siguiente:

Si bien todos se especificaron bajo las mismas variables, se puede observar que modelos como Random Forest y XGBoost si bien son capaces de modelar no linealidades, no alcanzaron el mismo nivel de precisión, posiblemente por limitaciones en la parametrización, falta de regularización óptima, menor capacidad de extrapolación o limitaciones computacionales.

SuperLearner, a pesar de ser un ensamble, no superó al modelo Keras, lo que sugiere que la red neuronal capturó suficientemente bien las relaciones sin necesidad de combinar múltiples algoritmos.

Modelos lineales como Elastic Net y OLS fueron superados ampliamente, lo que refuerza la necesidad de modelos no lineales en este problema.

Cuadro 4: Desempeño de modelos de predicción del precio de vivienda (MAE)

Modelo	MAE
XGBoost Tree	281.290.366,7
SuperLearner	283.366.395,4
CART	292.248.031,6
Random Forest	312.588.111,9
Elastic Net	338.869.433,6
OLS	284.214.140,8

4. Conclusiones

El presente estudio permitió demostrar el valor predictivo de los modelos de aprendizaje automático en la estimación del precio de oferta de viviendas en la localidad de Chapinero, Bogotá. A partir de una base de datos enriquecida con variables geoespaciales, estructurales y textuales, se construyeron diversos modelos, entre los cuales la red neuronal profunda y el algoritmo XGBoost mostraron los mejores desempeños en términos de error absoluto medio (MAE).

Uno de los hallazgos más relevantes fue que una arquitectura sencilla de red neuronal, con hiperparámetros moderados y sin imputación adicional de variables, superó a configuraciones más complejas y a otros modelos no lineales, como Random Forest o SuperLearner. Esto sugiere que, en contextos con datos limitados o propensos al sobreajuste, la simplicidad estructurada puede ser más efectiva que una complejidad excesiva. Asimismo, se destaca la importancia de transformar adecuadamente la variable objetivo, en este caso mediante logaritmo natural, lo cual permitió estabilizar la varianza y mejorar la precisión del modelo.

Además, el ejercicio evidenció el rol crucial del preprocesamiento de datos, incluyendo técnicas de normalización, codificación y generación de nuevas variables a partir de fuentes abiertas y procesamiento de lenguaje natural. Este enfoque integral no solo fortaleció la capacidad predictiva de los modelos, sino que también permitió una caracterización más rica del entorno urbano de los inmuebles.

Finalmente, aunque no se implementó validación cruzada espacial por limitaciones computacionales, el análisis sugiere que su inclusión en trabajos futuros podría mejorar aún más la robustez y generalización de los modelos. En conclusión, los resultados alcanzados validan el potencial del aprendizaje automático en el análisis inmobiliario y sientan una base sólida para aplicaciones similares en otras zonas urbanas de Colombia.

Referencias

5. Apéndice

5.1. Distribucion de la muestra por el espacio

Los siguientes mapas muestran la ubicación de los predios de la muestra en Bogotá, los colores verdes representan Apartamentos y los naranjas Casas.




Figura 6: Predios en otras localidades - train




Figura 7: Predios de Chapinero - Test

5.2. Imágenes de las variables y centroides

Aquí se presentan imágenes de las variables construidas para el ejercicio.




Figura 8: Centros Comerciales en Bogotá




Figura 9: Estratos




Figura 10: Avenidas Usadas




Figura 11: Parques en Bogotá segun Open Street Maps

Referencias

- [1] Ciencuadras. (2022). *Guía de barrio Chapinero - Barrios en Bogotá*. Recuperado de <https://www.ciencuadras.com/blog/guia-de-barrio-chapinero-bogota>
- [2] Chapinero 02. (s.f.). *Localidad de Chapinero - Chapinero 02 :: Real Estate*. Recuperado de <https://chapinero02.co/main-contenido-id-20033-localidad-chapinero.htm>
- [3] BluRadio. (s.f.). *Chapinero es la localidad con las casas más grandes en Bogotá*. Recuperado de <https://www.bluradio.com/regiones/bogota/ni-kennedy-ni-suba-localidad-casas-mas-grandes-bogota-rs15>
- [4] El País. (2024). *Bogotá defiende el nuevo Centro Felicidad de Chapinero frente a las críticas por su ubicación*. Recuperado de <https://elpais.com/america-colombia/2024-10-23/bogota-defiende-el-nuevo-centro-felicidad-de-chapinero-frente-a-las-criticas-por-su-ubicacion.html>
- [5] Amelica. (s.f.). *Impactos sociales del proceso de gentrificación en barrios de origen informal. Caso de la localidad de Chapinero, Bogotá*. Recuperado de <https://portal.amelica.org/ameli/journal/395/3951698005/html/>
- [6] Secretaría Distrital de Planeación. (2025). *Estratificación Manzana Bogotá D.C.* Recuperado de <https://datosabiertos.bogota.gov.co/dataset/55467552-0af4-4524-a390-a2956035744e/resource/29f2d770-bd5d-4450-9e95-8737167ba12f/download/manzanaestratificacion.json>
- [7] Secretaría Distrital de Planeación. (2024). *Gran centro comercial. POT Bogotá D.C.* Recuperado de <https://datosabiertos.bogota.gov.co/dataset/ce479dd9-7d54-4400-a05d-8df538c43e29/resource/c91f8dbd-f0a4-4fe1-83be-935a2de908da/download/gran.centro.comercial.geojson>
- [8] TRANSMILENIO S.A. (2019). *Trazados Troncales (Datos Abiertos TRANSMILENIO S.A.)*. Recuperado de <https://datosabiertos-transmilenio.hub.arcgis.com/datasets/trazados-troncales-de-transmilenio/explore?location=4.663582%2C-74.124750%2C11.88>
- [9] OpenStreetMap. (2025). *OpenStreetMap*. Recuperado de <https://www.openstreetmap.org/#map=19/4.690646/-74.056813>